

Exercise 1

α)

$$p(x|\theta) = \theta^2 \cdot x \cdot e^{-\theta \cdot x} \cdot u(x) \quad \text{όπου} \quad u(x) = \begin{cases} 1 & \text{για } x > 0 \\ 0 & \text{για } x < 0 \end{cases}$$

$$L(\theta|x) = f(x_1, x_2, \dots, x_n | \theta)$$

$$= \prod_{i=1}^N f(x_i | \theta) = \theta^2 \cdot x_1 \cdot e^{-\theta x_1} \cdot u(x_1) \times \theta^2 \cdot x_2 \cdot e^{-\theta x_2} \cdot u(x_2)$$

$$\times \dots \times \theta^2 \cdot x_N \cdot e^{-\theta x_N} \cdot u(x_N)$$

$$= \theta^{2N} \cdot e^{-\theta \cdot \sum_{i=1}^N x_i} \cdot \prod_{i=1}^N u(x_i)$$

$$\ln(L(\theta|x)) = \ln\left(\theta^{2N} \cdot e^{-\theta \cdot \sum_{i=1}^N x_i} \cdot \prod_{i=1}^N u(x_i)\right)$$

$$= \ln \theta^{2N} + \ln e^{-\theta \cdot \sum_{i=1}^N x_i} + \ln \prod_{i=1}^N u(x_i)$$

$$= 2N \cdot \ln \theta - \theta \cdot \sum_{i=1}^N x_i \cdot \ln e + \ln \prod_{i=1}^N u(x_i)$$

Επομένως:

$$\frac{\partial \ln(L(\theta|x))}{\partial \theta} = \frac{1}{\theta} \cdot 2N - \sum_{i=1}^N x_i$$

Και άρα: $\hat{\theta}_{ML} = \arg \max_{\theta} p(X|\theta)$

$$\hat{\theta}_{ML} : \frac{1}{\theta} \cdot 2N - \sum_{i=1}^N x_i = 0 \Leftrightarrow \boxed{\hat{\theta} = \frac{2N}{\sum_{i=1}^N x_i}}$$

$$(10) E[\hat{\theta}_{ML}] = E\left[\frac{2N}{\sum x_i}\right] = 2N \cdot \frac{1}{\sum_{i=1}^N E[x_i]} = 2N \cdot \frac{1}{N E[x_i]}$$

$$= \frac{2}{\frac{5 \cdot 2}{11,9}} = \frac{11,9 \cdot 2}{10} = \underline{2,38}$$

Exercise 2

(a)

$$\hat{\theta}_{\text{map}} = \operatorname{argmax}_{\theta} p(\theta|X) = \operatorname{argmax}_{\theta} \frac{p(\theta) \cdot P(X|\theta)}{p(Y)}$$

$$= \operatorname{argmax}_{\theta} (p(\theta) \cdot P(X|\theta)) = \operatorname{argmax}_{\theta} \ln(p(\theta) \cdot P(X|\theta))$$

Zuerst:

$$L(p(\theta) \cdot P(X|\theta)) = p(\theta) \cdot \prod_{i=1}^N p(x_i|\theta)$$

$$= \frac{1}{2\pi\sigma_0^2} \cdot e^{-\frac{(\theta-\theta_0)^2}{2\sigma_0^2}} \cdot \theta^2 \cdot x_1 \cdot e^{-\theta x_1} \cdot u(x_1) \times \dots \times \theta^2 \cdot x_n \cdot e^{-\theta x_n} \cdot u(x_n)$$

$$= \frac{1}{2\pi\sigma_0^2} \cdot e^{-\frac{(\theta-\theta_0)^2}{2\sigma_0^2}} \cdot \prod_{i=1}^N \theta^2 \cdot x_i \cdot e^{-\theta x_i} \cdot u(x_i)$$

$$= \frac{1}{2\pi\sigma_0^2} \cdot e^{-\frac{(\theta-\theta_0)^2}{2\sigma_0^2}} \cdot \theta^{2N} \cdot \prod_{i=1}^N x_i \cdot e^{-\theta \sum_{i=1}^N x_i} \cdot \prod_{i=1}^N u(x_i)$$

Apa:

$$\ln(L) = \ln \left[\frac{1}{2\pi\sigma_0^2} \cdot e^{-\frac{(\theta-\theta_0)^2}{2\sigma_0^2}} \cdot \theta^{2N} \cdot \prod_{i=1}^N x_i \cdot e^{-\theta \sum_{i=1}^N x_i} \cdot \prod_{i=1}^N u(x_i) \right]$$

$$= \ln \frac{1}{2\pi\sigma_0^2} + \frac{-(\theta-\theta_0)^2}{2\sigma_0^2} \cdot \ln e + 2N \cdot \ln \theta + \ln \prod_{i=1}^N x_i - \theta \sum_{i=1}^N x_i$$
$$+ \ln \prod_{i=1}^N u(x_i)$$

~)

Οπότε:

$$\frac{\partial \ln(L)}{\partial \theta} = \frac{-(2\theta - 2\theta_0)}{2\sigma_0^2} + 2N \frac{1}{\theta} - \sum_{i=1}^N x_i$$

$$\text{Θέλουμε } \frac{\partial \ln(L)}{\partial \theta} = 0 \Leftrightarrow$$

$$\frac{2\theta_0 - 2\theta}{2\sigma_0^2} + 2N \cdot \frac{1}{\theta} - \sum_{i=1}^N x_i \stackrel{(\times 2\sigma_0^2 \cdot \theta)}{\Leftrightarrow}$$

$$\theta(2\theta_0 - 2\theta) + 2N\sigma_0^2 - 4\sigma_0^2\theta \sum_{i=1}^N x_i = 0 \Leftrightarrow$$

$$-2\theta^2 + 2\theta_0\theta + 2N\sigma_0^2 - 4\sigma_0^2 \sum_{i=1}^N x_i \cdot \theta = 0 \Leftrightarrow$$

$$-\theta^2 + (\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i) \cdot \theta + 2N\sigma_0^2 = 0 \Leftrightarrow$$

$$\theta^2 - (\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i) \cdot \theta - 2N\sigma_0^2 = 0 \quad (1)$$

$$\Delta = (\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i)^2 + 8N\sigma_0^2 > 0$$

$$\theta_{1,2} = \frac{(\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i) \pm \sqrt{(\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i)^2 + 8N\sigma_0^2}}{2} \quad (*)$$

$$\theta_1 = \hat{\theta} = \frac{(\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i) + \sqrt{(\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i)^2 + 8N\sigma_0^2}}{2}$$

*!! Έστω $c = (\theta_0 - \sigma_0^2 \sum_{i=1}^N x_i)$ και $a = 8N\sigma_0^2 > 0$

Συνεπώς $c < \sqrt{c^2 + a}$ όπου a ένας θετικός αριθμός.
Άρα $\hat{\theta}_2 < 0$, απορ. γιατί θέλουμε $\hat{\theta} > 0$.

$$\textcircled{b} \textcircled{i} \Leftrightarrow \frac{\theta^2}{\sigma_0^2} - \theta \left(\frac{\theta_0}{\sigma_0^2} - \frac{\sigma_0^2 \sum x_i}{\sigma_0^2} \right) - 2N \cancel{\sigma_0^2} \cdot \frac{1}{\cancel{\sigma_0^2}} = 0 \Leftrightarrow$$

$$\frac{\theta^2}{\sigma_0^2} - \theta \left(\frac{\theta_0}{\sigma_0^2} - \sum_{i=1}^N x_i \right) - 2N = 0 \quad (2)$$

\textcircled{i} Όταν το $N \rightarrow \infty$ το $\hat{\theta}$ συγκλίνει στο πραγματικό θ γιατί είναι "σαν" να έχουμε όλα τα σημεία του πληθυσμού!

\textcircled{ii} Όταν το $\sigma_0^2 \gg$ τότε η (2) γίνεται:

$$\frac{\cancel{\theta^2}}{\cancel{\sigma_0^2}} - \theta \left(\frac{\cancel{\theta_0}}{\cancel{\sigma_0^2}} + \sum_{i=1}^N x_i \right) - 2N = 0 \Leftrightarrow$$

$$\theta_{\text{MAP}} = \frac{2N}{\sum_{i=1}^N x_i} = \hat{\theta}_{\text{ML}} \quad (\text{Exercise 1})$$

Το παραπάνω αποτέλεσμα μπορούμε να το αντιληφθούμε και με άλλη λογική αφού όταν το σ_0^2 από τη "prior" γνώση είναι πολύ μεγάλο τότε και η "αβεβαιότητα" για το θ_0 είναι τόσο μεγάλη που δεν επηρεάζει τη $\hat{\theta}_{\text{MAP}}$ εκτίμηση.

\textcircled{iii} Αντίθετα, όταν $\sigma_0^2 \ll$ τότε $\hat{\theta}_{\text{MAP}} = \theta_0$ γιατί είμαστε πολύ "βέβαιοι" για τη γνώση που έχουμε από την prior πληροφορία.